Wi-Fi CSI 跨人员动作识别基线实验报告

ESP32 / ESP-Fi HAR / LightweightCNN

一次固定划分、单一随机种子的冻结实验

摘要 本实验研究模型未见过某位参与者时，能否仅依据 Wi-Fi CSI 幅度序列识别其动作。使用 ESP-Fi HAR 的七类动作数据，固定 P1–P5 训练、P6 验证、P7–P8 测试。仅训练集拟合通道标准化，采用 35,655 参数的一维卷积网络。正式训练完成 26 轮并早停，按预设验证规则选定第 16 轮；Val Accuracy 为 27.1429%，Test Accuracy 为 26.4286%、Macro-F1 为 0.257181。当前基线跨人员表现有限，结果不构成跨环境泛化或真实部署能力的证据。

关键词 Wi-Fi CSI；跨人员动作识别；1D CNN；训练集标准化；ESP-Fi HAR

1 研究问题与数据集

CSI 描述无线传播信道的状态。本项目直接读取作者提供的幅度变量 `CSIamp`，不处理相位。数据来源及编号约定参照作者仓库 [1]，CSI 的基本表示参照官方文档 [3]。人体运动可能改变反射和遮挡，但本实验没有对具体传播因素做独立因果验证。

本地审计确认有 2,240 对 MAT/CSV 样本，四个环境各 560 对：走廊、办公室、会议室、实验室。七类动作为跑步、跌倒、行走、转身、跳跃、下蹲、挥手。文件名 `X-Y-Z-M` 依次表示环境、人员、动作和重复编号。单个 MAT 数组形状为 `(950,52)`，分别作为时间位置和幅度通道使用；仅凭形状不能推出采样率、持续时间或具体子载波频率。MAT 和 CSV 是配对文件，不能将其算成 4,480 个独立样本。

2 固定跨人员划分与隔离

表 1 固定人员划分。所有集合均包含四个环境和七类动作。

集合	参与者	样本数	用途
Train	P1–P5	1400	拟合标准化、更新模型权重
Validation	P6	280	选择 checkpoint、早停
Test	P7–P8	560	模型冻结后一次正式测试

划分来自冻结的 `dataset_split.csv`，人员集合互不重叠，不随机重划分。训练的 shuffle 只改变训练样本顺序。P6 指标参与选模，不属于独立的最终测试；P7–P8 未用于拟合或选模。四个环境均出现于各集合，因此这里不是留一环境实验。

3 训练集通道标准化

只用 P1–P5 的全部 1400 个样本，在每个通道上合并 950 个时间位置，每通道统计 $1400\times950=1{,}330{,}000$ 个值。使用 float64 分块累积计算均值 μ_c 和总体标准差 σ_c（ddof=0），输入变换为

$$z_{c,t}=\frac{x_{c,t}-\mu_c}{s_c},\qquad s_c=\begin{cases}1, & \sigma_c<10^{-8},\\ \sigma_c, & \sigma_c\geq10^{-8}.\end{cases}\tag{1}$$

本次没有近零标准差通道。52 通道均值范围为 51.457561–82.272568，标准差范围为 20.789327–28.434454。这些是训练集统计，不是测试指标。

三个集合共用 `csi_normalizer.npz`，不分别拟合。标准化后返回 float32；原始 MAT 不变。

4 LightweightCNN 结构与参数核算

Dataset 按样本读取数据 [5]，将 `(950,52)` 转置为 `(52,950)`，标签从 1–7 减一到 0–6。Batch 为 `(B,52,950)`，最终输出 `(B,7)` logits，不在损失前加 Softmax[4]。

表 2 唯一基线模型。参数量已与实际 PyTorch 模型逐层核对。

层	主要设置	输出形状（省略 B）	参数量
Conv1d + ReLU	52→64，核 3，padding1	(64, 950)	10048
MaxPool1d	核 2	(64, 475)	0
Conv1d + ReLU	64→128，核 3，padding1	(128, 475)	24704
AdaptiveAvgPool1d	输出长度 1	(128, 1)	0
Flatten	保留 Batch 轴	(128)	0
Linear	128→7	(7)	903
合计			**35,655**

核算为 $(52\times3+1)\times64=10{,}048$，$(64\times3+1)\times128=24{,}704$，$(128+1)\times7=903$，加和正确。

图 1 中，两次卷积沿时间提取特征，最大池化减半时间长度，全局平均池化将时间轴压缩为 1，最后线性层输出七类 logits。

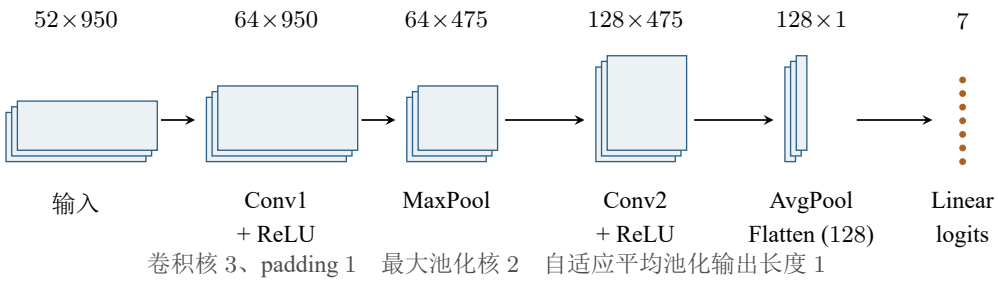


图 1 LightweightCNN 的张量流。横向为时间轴，叠层表示通道；仅示意结构，不代表实际信号或等比例几何。省略 Batch 轴，全部维度来自 `src/model.py`。

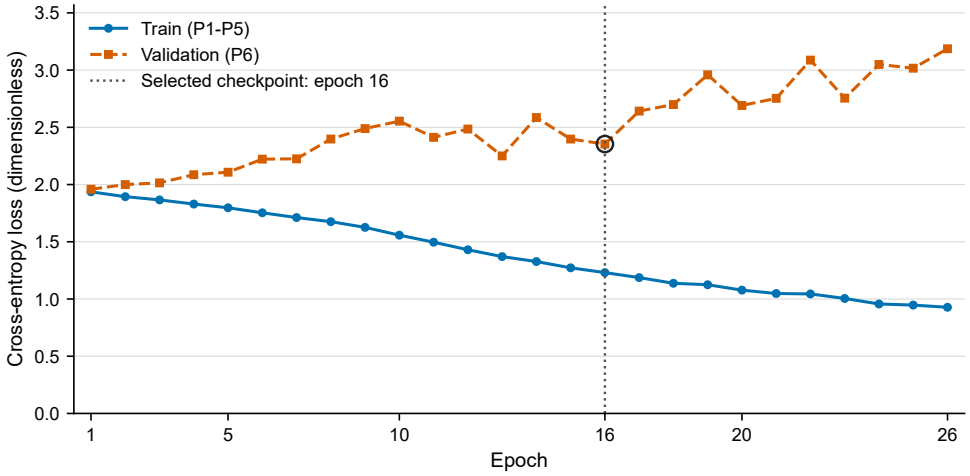
5 训练配置及早停规则

Seed=42，Batch Size=32，Adam，学习率 0.001，weight decay=0，CrossEntropyLoss；GPU 为 NVIDIA GeForce RTX 3060 Laptop GPU。上限 40 轮，patience=10，无超参数搜索。每轮 44 次训练更新；验证使用 `eval()` 和 `no_grad()`，不更新权重。以 Val Accuracy 优先、相同时 Val Loss 更低选模；完全相同不算改善。第 16 轮之后连续 10 轮未改善，第 26 轮早停，共 1,144 次更新。Smoke Test 不计入正式结果。

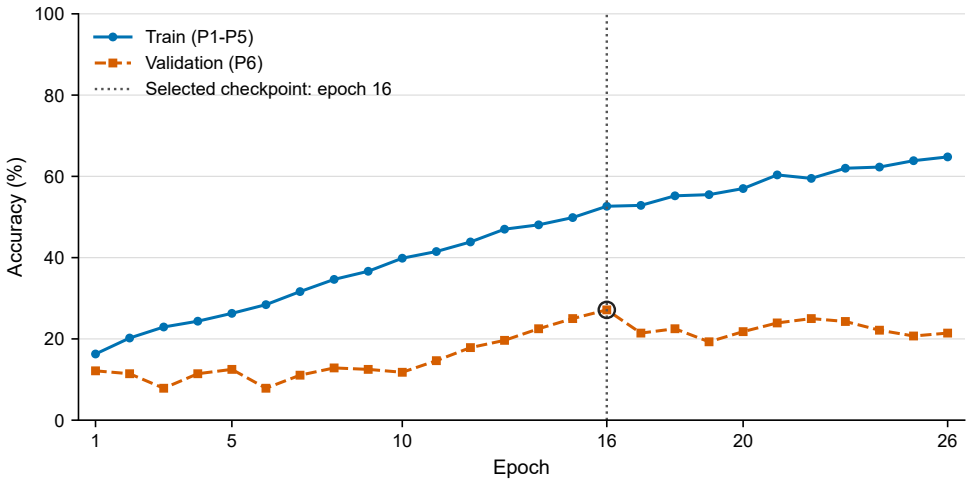
6 完整训练过程与验证选择

图 2 保留全部 26 轮原始记录点，不平滑、不插值补点。两幅子图共用 Seed 42、训练 n=1400、验证 n=280；竖线标出按验证规则选中的第 16 轮。

最佳轮 Train Loss=1.230499，Train Accuracy=52.6429%，Val Loss=2.353830；末轮 Train/Val Accuracy=64.7857%/21.4286%，泛化差距明显。



(a) 交叉熵损失：训练下降，验证总体上升。



(b) 准确率（%）：训练与验证差距扩大。

图 2 完整 26 轮训练与验证记录。最佳验证准确率为 27.1429%；训练准确率按各 Batch 更新时的预测累计。单一随机种子，无重复实验置信区间。

7 冻结模型的正式测试

只使用第 16 轮 checkpoint；不使用第 26 轮或根据测试表现重新选模。以固定标准化参数、`eval()` 和 `no_grad()` 遍历 P7–P8 共 560 个样本一次。

表 3 冻结测试结果。Macro-F1 等权平均全部七类，零分母按 0 处理。

评价指标	正式结果
Test Accuracy	**26.4286%**（148/560）
Test Macro-F1	**0.257181**
测试样本 / 每类 Support	560 / 80

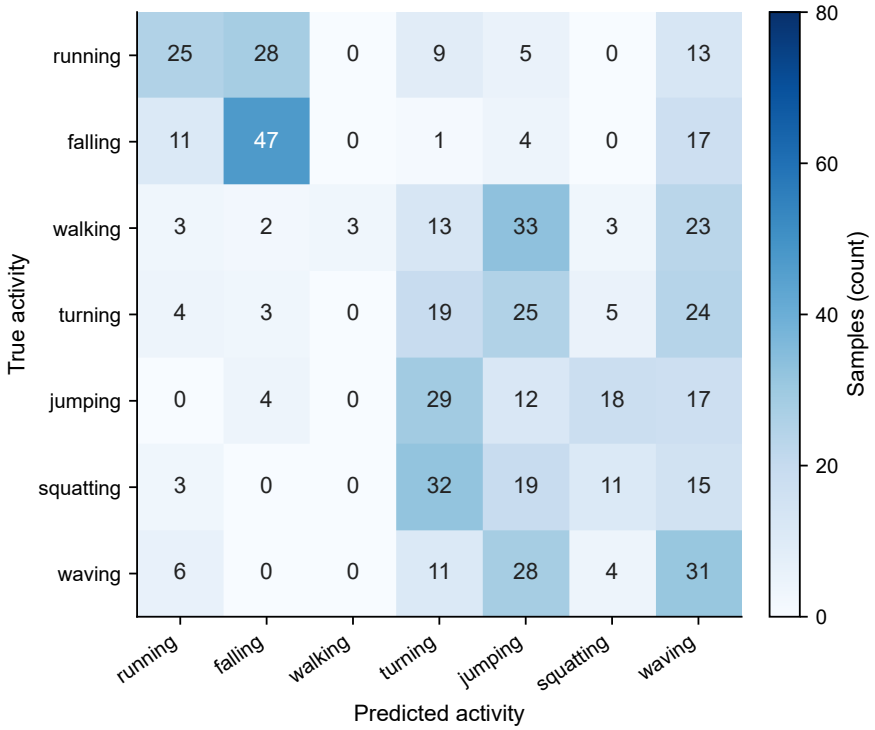


图 3 正式测试混淆矩阵。行是真实类别，列是预测类别，每格为计数，矩阵总和 560；所有数值直接来自冻结预测。

图 3 显示错误并非均匀分布：walking 经常被预测为 jumping，squatting 经常被预测为 turning。该观察描述误分类结构，不能单凭它确定物理成因。

8 各类动作表现

表 4 和图 4 同时呈现 Precision、Recall 和 F1，避免只看整体 Accuracy。

表 4 七类动作的正式测试指标，固定标签顺序 0–6。

动作	Precision(%)	Recall(%)	F1(%)	Support
跑步	48.08	31.25	37.88	80
跌倒	55.95	58.75	57.32	80
行走	100.00	3.75	7.23	80
转身	16.67	23.75	19.59	80
跳跃	9.52	15.00	11.65	80
下蹲	26.83	13.75	18.18	80
挥手	22.14	38.75	28.18	80

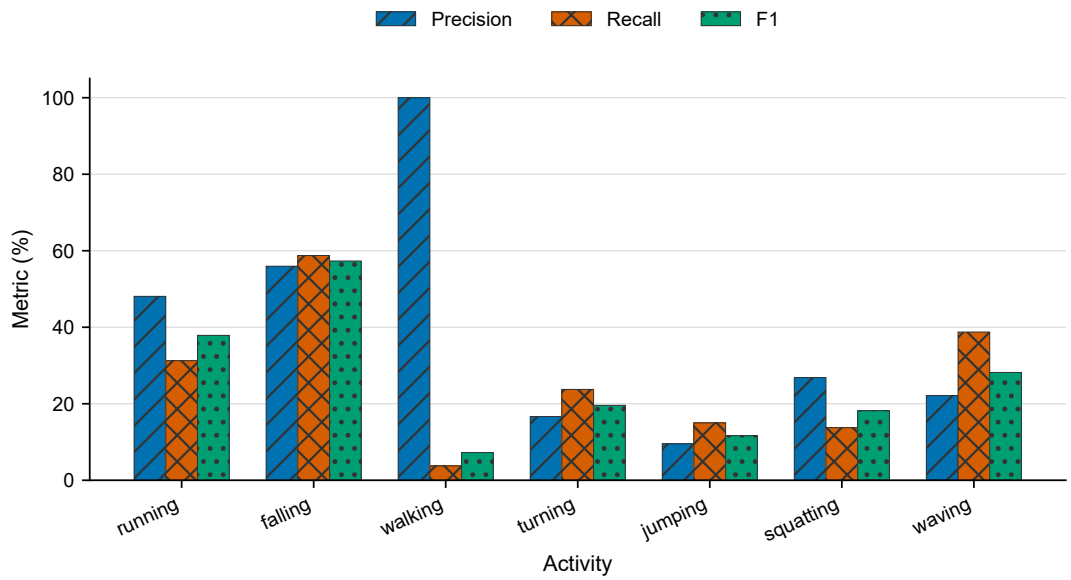


图 4 类别差异：falling 的 F1 最高，walking 的 Recall 最低。各类 Support=80；单一冻结模型。

falling 的 F1 为 0.573171，walking 为 0.072289。walking 的 Precision=100% 仅基于 3 个预测，Recall=3.75%。高 Precision 不意味着高覆盖率：walking 预测虽少而正确，却漏掉多数真实 walking。上述结果来自单一冻结模型，没有跨 seed 或划分的误差条。

9 人员差异与主要错误

表 5 P7/P8 的辅助分析，不用于重新选择模型或预处理。

人员	样本数	Accuracy	Macro-F1
P7	280	23.9286%	0.226313
P8	280	28.9286%	0.247832

P8 Accuracy 比 P7 高 5 个百分点，但不能据此认为所有动作均更容易识别，也不能声称差异具有统计显著性。合并 Macro-F1 不等于两位人员 Macro-F1 的简单平均。

表 6 主要非对角错误；比例以每个真实类别的 80 个样本为分母。

真实 → 预测	数量	真实类别内比例
行走 → 跳跃	33	41.25%
下蹲 → 转身	32	40.00%
跳跃 → 转身	29	36.25%
挥手 → 跳跃	28	35.00%
跑步 → 跌倒	28	35.00%
转身 → 跳跃	25	31.25%

10 实验局限与结论

观察事实：训练 Loss 从 1.936258 降至 0.927492，末轮 Val Loss 升至 3.186177；训练表现改善未同步转化为验证表现改善。这些记录支持过拟合或跨人员泛化不足的判断，而不是良好泛化收敛。

可能原因：动作执行习惯、传播条件差异和有限训练人员可能带来分布偏移；轻量网络及时间平均池化也可能限制表达能力。但本实验没有相应对照，不能将其中任何一项写成已证实的因果解释。

解释边界：只有一个 seed、一次划分、两名测试人员；同一人员和环境内样本相关，不能把 560 个样本视为 560 名独立人员。P6 参与选模，且四环境均进入各集合。未验证跨环境留出、在线实时识别、硬件迁移或真实部署可靠性。

结论：该实验建立了可追溯的幅度 1D CNN 跨人员基线，测试结果为 26.4286% 和 0.257181。工程流程可复现不等于识别能力理想；当前泛化表现有限。结果已经冻结，本报告不进行第二次训练、测试或调参。

11 来源审计与参考资料

本报告沿用冻结结果；完整 SHA256 与工程记录保留于既有 provenance 文件。文献 [2] 仅采用已核实的 arXiv v2，作为背景资料。

参考文献

[1] AutoSmartGroup. ESP-Fi HAR: A Low-Power WiFi CSI Dataset for Ad-Hoc IoT Human Activity Recognition. 作者数据集及代码说明。https://github.com/AutoSmartGroup/ESP-Fi-HAR.

[2] Hongbo Wang, Xin Li, Yinghui He, Jingzhi Hu, Mingming Xu, Zhe Chen, Fu Xiao, Jun Luo. Path to Diversity: A Primer on ISAC-izing Commodity Wi-Fi for Practical Deployments. arXiv:2601.12980v2, 2026. https://arxiv.org/abs/2601.12980v2.

[3] Espressif Systems. ESP-IDF Programming Guide: Wi-Fi Channel State Information. https://docs.espressif.com/projects/esp-idf/en/stable/esp32/api-guides/wifi-driver/wifi-vendor-features.html.

[4] PyTorch. CrossEntropyLoss, PyTorch 2.14 documentation. https://docs.pytorch.org/docs/2.14/generated/torch.nn.CrossEntropyLoss.html.

[5] PyTorch. Datasets and DataLoaders, Learn the Basics. https://docs.pytorch.org/tutorials/beginner/basics/data_tutorial.html.